


MIMCS - 2026. SZEPTEMBER 24.

Adatvédelem a modellhívásokban

Helyi proxy coding agentekhez

Koren Miklós
koren.dev



Egy modellhívás a promptnál többet is tartalmazhat

Coding agent

Felhasználói
utasítások

Fájlok
forráskód és konfiguráció

Eszközök
terminál- és MCP-kimenetek

Állapot
változások és előzmények

Felhőmodell

A modellhívás helyi adatot is tartalmazhat.

```
Anna Kovacs
```

```
anna@example.hu
```

```
DB_PASSWORD=***
```

Minden kimenő modellhívást szűrni kell.

Három eszközcsoport

01

Szabályok és könyvtárak

Reguláris kifejezések
Ellenőrző összegek
Presidio
scrubadub

Gyors és auditálható

Kontextusfüggő esetekben
bizonytalan

02

Távoli szolgáltatások

Felhős DLP-szolgáltatások
Felhőben futó adatelfedés
Vállalati átjárók

Széles lefedettség

Az adat elhagyja a gépet

03

Helyi modellek

Rampart
Desert Ant Redact
LFM2.5
GLiNER2

Az adat helyben marad

Proxyba építhető

A szabályok egyértelmű formátumokat ismernek fel

STRUKTURÁLT AZONOSÍTÓK

Strukturált adatok

E-mail-címek
Hitelkártyaszámok Luhn-ellenőrzéssel
IP-címek
Nemzeti azonosítószámok
Ismert titkok és API-kulcsformátumok


KONTEXTUSFÜGGŐ AZONOSÍTÓK

A kontextus dönti el

A vezetéknév személyhez, fájlnevhez vagy cégnévhez tartozik-e?
Dátum: születésnap vagy kiadási dátum?
Az elérési út azonosít-e munkavállalót?

A kontextusfüggő eseteket helyi modell kezeli.

Távoli adatelfedővel a személyes adat is kikerül a gépről



Indokolt

Központi szabályzat, dokumentumfeldolgozás, OCR vagy szabályozott auditfolyamat.

Kizárt


A szabályzat tiltja, hogy személyes adat elhagyja a kliensgépet.

Hat vizsgált modell

MODELL	FEJLESZTŐ	PARAMÉTERSZÁM	FÁJLMÉRET	NYELVEK	KÖRNYEZET	KIMENET
Rampart	National Design Studio	18,5M	14,7 MB	7	Böngésző, Node	Típusjelölt, állandó tokenek
Desert Ant Redact	Desert Ant Labs	23M	11,6-24,5 MB	27	Böngésző, Node, natív	Típus szerinti címkék
GLiNER2-PII	Fastino	205M	nincs megadva	7	Python, CPU	Szövegrészletek vagy elfedés
LFM2.5 PII	Liquid AI	350M	modellfüggő	16	Transformers, CPU	Címkézett szövegrészletek
PII-Tracer	Perplexity	kb. 600M	változatfüggő	nincs megadva	GGUF, MLX, vLLM	Címkézett placeholderek
Nemotron v2	OpenMed	1,4B / 50M aktív	változatfüggő	20	Transformers, MLX	55 címketípus

A fejlesztő is számít, nemcsak a műszaki adatok.

A proxy szabja meg, mi kerül a felhőbe



Nyers helyi adat

Anna Kovacs `anna@example.hu`

Helyettesített kérdés

`<PERSON:7F2A>` `<EMAIL:9B11>`

A tokeneket csak a proxy cseréli vissza. A helyettesítési tábla helyben marad.

A kérés útja a proxyn át

01

Elfogás

Kimenő
modellhívás

02

Felismerés

Szabályok és helyi
modell

03

Helyettesítés

Személyes adat
helyett token

04

Tárolás

A helyettesítési
tábla rövid ideig
marad helyben

05

Visszaállítás

Csak korábban
kiadott tokeneket
cserél vissza

Nyers adat és helyettesítési tábla: a gépen maradnak.

Két naplóban látszik, mit kap az OpenRouter

Helyi napló

PROXY.RECEIVE

Anna Kovacs
anna@example.hu

PROXY.DETECT

PERSON EMAIL

PROXY.MAP

7F2A = Anna Kovacs

OpenRouter-napló

REQUEST.INPUT

<PERSON:7F2A>

<EMAIL:9B11>

PROVIDER.OUTPUT

Mondd meg <PERSON:7F2A> ...

NINCS A NAPLÓBAN

Nyers adat, helyettesítési tábla

A demonstráció útja

01

Coding agent

Nyers kérdés és adattár-
környezet

02

Helyi proxy

Felismerés és
helyettesítés

03

OpenRouter

Helyettesített kérdés

04

Coding agent

Visszaállított válasz

Helyi nézet

Nyers kérdés, találatok, helyettesítési tábla

OpenRouter Broadcast

A távoli szolgáltatásnak küldött kérdés

A regex nem tudja, mi számít névnek

John McClane

Személynév egy film történetében.

A szövegalak önmagában nem dönt.

Die Hard

Filmcím, nem személynév.

A helyes címkéhez kontextus kell.

A névfelismerés szemantikai feladat, nem egyszerű mintakeresés.

A modell a kitakart nevet is azonosította

HELYI FELISMERÉS

A Rampart helyesen elfedte: John McClane

TÁVOLI KÖVETKEZTETÉS

A modell a történetből visszaazonosította a szereplőt.

A sikeres elfedés nem garantál anonimitást, ha a megmaradó kontextus egyedi.

```
1: { 2 Items
  role: "user"
  content: [ 1 Item
    0: { 2 Items
      type: "text"
      text: "<GIVEN_NAME:3CC0C1E3> <SURNAME:B41E9224> is the hero of Die Hard. Who is the actor?"
    }
  ]
}
```

A FELHŐBE KÜLDÖTT KÉRÉS

```
{ 4 Items
  completion: "Bruce Willis played <GIVEN_NAME:3CC0C1E3> <SURNAME:B41E9224> (John McClane) in the 1988 film *Die Hard*."
  reasoning: "The user is asking about the movie Die Hard and who plays the main character (John McClane). This is a straightforward question about pop culture."
```

Bruce Willis plays John McClane in Die Hard. The user's message starts with a placeholder '<GIVEN_NAME:3CC0C1E3>' which is a redacted given name, and '<SURNAME:B41E9224>' which is a redacted surname. These placeholders were inserted by the privacy proxy. The original text was likely "John McClane" or some variation, with the names replaced by placeholders

A MODELL VÁLASZA ÉS INDOKLÁSA

A korlátozott modell a gépen kezdett keresni

KÉRÉS

Who is Bruce Willis?

MEGFIGYELÉS

A név elfedése után a modell összezavarodott, majd helyi keresést indított.

Az elfedés a promptot védi. A harness és az eszközök más útvonalakat nyitnak.

```
1: { 2 Items▼  
  role: "user"  
  content: [ 1 Items▼  
    0: { 2 Items▼  
      type: "text"  
      text: "Who is <GIVEN_NAME:2D8FAB1D>  
            <SURNAME:FE19618C>?"  
    }  
  ]  
}
```

A FELHŐBE KÜLDÖTT KÉRÉS

Magyarul a felismerés és a következtetés is hibázott

KÉRÉS

Kicsoda Hajnóczy Péter?

ELFEDÉS

Csak a „Péter” részt fedte el; a „Hajnóczy” kikerült.

VÁLASZ

A modell Hajnóczy Józseffel keverte össze.

Egyszerre tért vissza az adatszivárgás és a hallucináció.

```
1: { 2 Items ✓  
  role: "user"  
  content: [ 1 Items ✓  
    0: { 2 Items ✓  
      type: "text"  
      text: "Kicsoda Hajnóczy  
        <GIVEN_NAME:7E706392>?"  
    }  
  ]  
}
```

A VEZETÉKNÉV KIKERÜLT, A KERESZTNÉV HELYŐRZÓT KAPOTT

A pontosságon kívül ezeket is nézzük

Lefedettség	Személyes adatok típusai és támogatott nyelvek
Terjedelem	Paraméterszám, modellfájlméret és kvantálás
Futtatás	CPU, böngésző, natív SDK és memóriaigény
Működés	Címkézett szövegrészletek, törlés, tokenek, visszahelyettesítés
Irányítás	Licenc, telemetria és saját kód igénye

A pontosságot saját kérések címkézett mintáján mérjük. A gyártó tesztkészlete nem elég.

A PII-elfedés csak egy csatornát zár le

- Felismerés: egy kihagyott név kiszivárog
- Modelltudás: az identitás visszakövetkeztethető
- Harness és eszközök: új adatútvonalak nyílnak

Egy nagyon okos agy egyik kezét kötöttük meg. A többi kezét is vizsgálni kell.