A hálózat mint adat: mit tanulhatunk ritka mobilitási gráfokból?

Koren Miklós Ulrich Wohak Orbán Krisztina

Hálózatok: helyi hatások és globális szerkezet

Hogyan hatnak ránk a szomszédaink?

Kollégiumi szobatársak hatása egymásra (Sacerdote 2001)

Importálási tudás terjedése szomszédos vagy közös vezetővel működő vállalatok között (Bisztray, Koren és Szeidl 2018)

Közvetlen szomszédok hatása; hosszabb láncok és alternatív utak.

Jackson: *Social and Economic Networks* (2008).

Az egész hálózat szerkezete

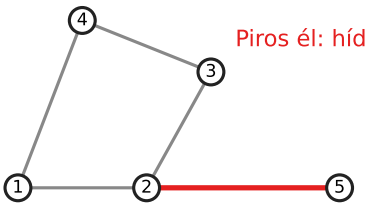
Erdős–Rényi: véletlenszerű kapcsolatok (Erdős és Rényi 1959)

Barabási–Albert: a nagy fokszámú csúcsok több új kapcsolatot vonzanak; széles fokszámeloszlás (Barabási és Albert 1999)

Néhány paraméter, globális szabályszerűségek.

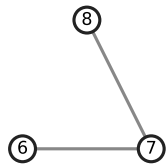
Olvasmány: Barabási Albert-László, *A hálózatok tudománya*.

Csúcsok, élek, komponensek és körök



Piros él: híd

1 komponens, benne kör



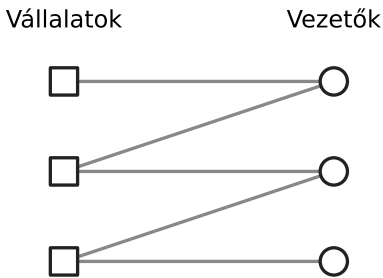
Másik komponens

Komponens: utakkal összekötött csúcsok.

Kör: visszatérés a kezdőpontba, él és közbülső csúcs ismétlése nélkül.

Fokszám: szomszédok száma; a 2. csúcsé 3.

Kétféle csúcs: a páros gráf



Élek csak a két csoport között.

Vállalat–vezető; vevő–termék; bank–hitelfelvevő.

Ritka hálózat

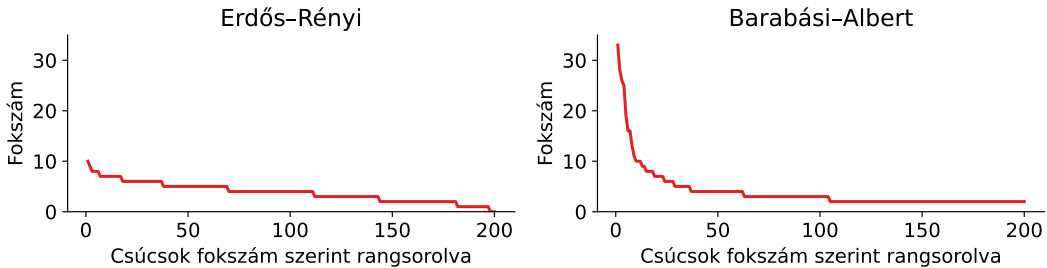
Lehetséges kapcsolatok:

N csúcs, egyszerű irányítatlan gráf: $N(N-1)/2$.

N_f vállalat, N_m vezető: $N_f N_m$.

Magyar adatok: 1.94×10^6 megfigyelt kapcsolat / 1.35×10^{12} lehetséges pár.

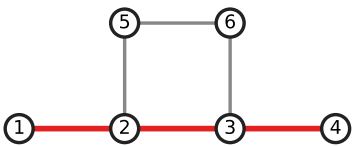
Néhány csúcsnak sokkal több szomszédja van



Két szimulált hálózat, egyenként 200 csúcs.

Skálafüggetlen modell: a nagy fokszámok gyakorisága hatványfüggvény szerint csökken.

Séta, út és távolság



1–2–3–4: út, 3 lépés

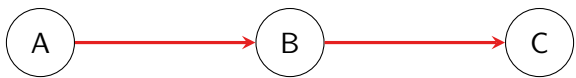
1–2–5–2–3: séta, ismétléssel

Séta: csúcsismétlés megengedett; egy él = egy lépés (hop).

Út: csúcsismétlés nélkül.

Távolság: a legrövidebb út hossza. Átmérő: a komponens legnagyobb távolsága.

Amikor a kapcsolat iránya is számít



Bejövő és kimenő fokszám: ki fizet kinek?

Nálunk: irányítatlan gráf; egy vállalat–vezető pár = egy él, ismételt megbízatás esetén is.

A mátrixhatványok sétákat számolnak



A

0	1	0
1	0	1
0	1	0

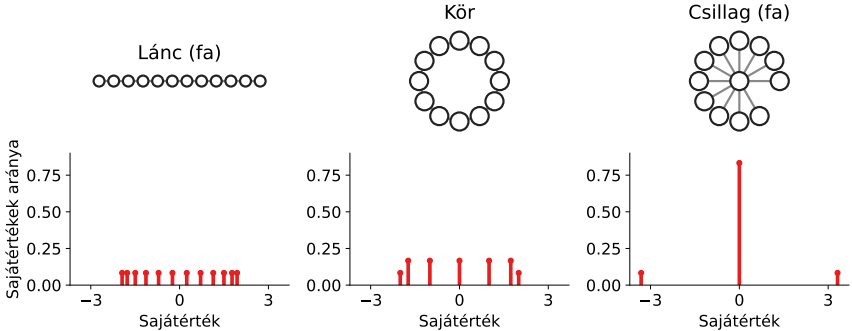
A^2

1	0	1
0	2	0
1	0	1

$A_{ij} = 1$, ha van él; egyébként 0.

$(A^k)_{ij}$: k lépéses séták száma. Visszatérés is: $(A^2)_{22} = 2$.

Sajátértékek és mátrixhatványok



12 csúcs, eltérő gráfok és sajátérték-eloszlások.

$$A\mathbf{v} = \lambda\mathbf{v} \quad \Rightarrow \quad A^k\mathbf{v} = \lambda^k\mathbf{v}.$$

Közösségkeresés a hálózati mátrix sajátértékeivel és sajátvektoraival.

Miért számít a vezetők és a vállalatok párosítása?

Számít-e az összkibocsátásban, hogy ki melyik vállalatot vezeti?

Koren, Wohak és Orbán: *Better Executives Work at Better Firms* (folyamatban).

Az erőforrások rossz elosztása csökkenti az aggregált termelékenységet (Hsieh and Klenow 2009)

Számít-e az összkibocsátásban, hogy ki melyik vállalatot vezeti?

Koren, Wohak és Orbán: *Better Executives Work at Better Firms* (folyamatban).

Az erőforrások rossz elosztása csökkenti az aggregált termelékenységet (Hsieh and Klenow 2009)

A vezetők döntései az egész vállalatra kihatnak.

A párosítás az egész gazdaság termelékenységét befolyásolja.

Jobb vezetők a jobb vállalatoknál

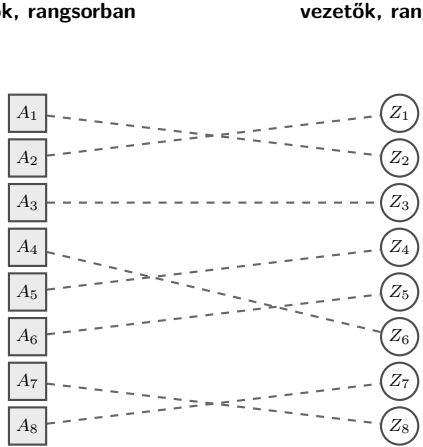
A vállalati termelékenység (A_i) és a vezetői képesség (Z_m) kiegészítik egymást:

$$Y = \sum_{(i,m)\in\mathcal{M}} A_i Z_m.$$

Rögzített peremeloszlások és párszám: a pozitív párosítás növeli a kibocsátást.

Mennyire erős ez a pozitív szelekció a vezetők és a vállalatok között?

Ki melyik vállalatot vezeti?



Milyen messze van a gazdaság a tökéletes pozitív párosítástól?

Módszer ritka mobilitási hálózatokra

Mobilitási láncok mentén együtt mozgó vállalati teljesítmények.

A hálózati modellben a kovariancia lecsengési üteme azonosítja a szelekciót.

Magyarország: becsült korreláció **0.5**; véletlen párosítással **12.3%-kal** kisebb várható árbevétel.

A vezetők ritka mobilitási hálózata

A magyar vállalatvezetők mobilitási hálózata, 1990-2022

Vállalat–vezető kapcsolatok; teljesítmény vezetői időszakonként.

.	Érték
Vezetők	1,300,885
Vállalatok	1,036,230
Egyedi vállalat–vezető kapcsolatok	1,936,933
Kapcsolatok az óriáskomponensben	**828,549 (42.8%)**
Összefüggő komponensek	511,418
Hidak aránya az élek között	**81.7%**
Átlagos vezetőtávolság az óriáskomponensben	19.6

A teljes vállalati körhöz a kis komponensek is hozzátartoznak

Cégnyilvántartás + a kettős könyvvitelt vezető vállalatok éves beszámolói.

Egy él: egyedi vállalat–vezető pár. Egy teljesítményadat: változatlan vezetői csapat.

Az óriáskomponensben: a vállalatok **33.2%-a**, a vezetők **29.8%-a**.

A fixhatásos becsléshez összekötő utak kellenek

Fix hatások: komponensenként külön normalizálás.

Leave-out korrekció: az elhagyott megfigyelés után is becsülhető hatások.

Vezetői hálózatok: sok kis komponens és híd. (Abowd, Kramarz and Margolis 1999; Kline, Saggio and Sølvsten 2020)

A leave-out becslés minden tizedik párt tartja meg

Kiinduló minta: teljesítményadattal rendelkező párok.

Lépés	Párok száma	%
Összes egyedi vállalat–vezető pár	1,732,154	100.0%
Hidak elhagyása (leverage $= 1$)	265,995	15.4%
Legnagyobb leave-out-összefüggő blokk	175,661	**10.1%**

A szelekció mérése mobilitási láncok mentén

A vállalati teljesítmény legegyszerűbb modellje

A vállalat teljesítménye az m vezető irányítása alatt:

$$y_{im} = a_i + z_m + \varepsilon_{im}.$$

a_i: vállalati adottságok; z_m: vezetői képesség. A teljesítményből becsüljük őket.

Egy lánc különböző vállalatok teljesítményét kapcsolja össze

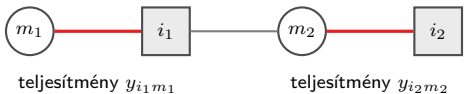
$$m_1 - i_1 - m_2 - i_2$$

m_2 átveszi m_1 helyét az i_1 vállalatnál, majd az i_2 vállalatot vezeti.

$y_{i_1 m_1}$ és $y_{i_2 m_2}$: különböző vállalatok, különböző vezetők.

Pozitív szelekció: együtt mozgó tartós teljesítmény.

A szelekcióból eredő kovariancia



Az m_1 és i_2 végpontokat $h = 3$ él választja el. Különböző vállalatok teljesítményét kapcsoljuk össze.

A szelekcióból eredő kovariancia:

$$\rho(\sigma_a + \rho\sigma_z)(\sigma_z + \rho\sigma_a).$$

A kovariancia lecseng a mobilitási fa mentén

Ha a végpontokat h él választja el:

$$\mathrm{Cov}(P - F - ... - F - P) = \rho^{h-2} (\sigma_a + \rho\sigma_z)^2$$
$$\mathrm{Cov}(F - P - ... - P - F) = \rho^{h-2} (\rho\sigma_a + \sigma_z)^2$$
$$\mathrm{Cov}(P - F - ... - P - F) = \rho^{h-2} (\sigma_a + \rho\sigma_z)(\rho\sigma_a + \sigma_z)$$

A kovariancia **szintje** a σ_a, σ_z és ρ paraméterektől együttesen függ.

Két további lépés ρ^2-szeresére csökkenti a kovarianciát.

Mit azonosít a lecsengés üteme?

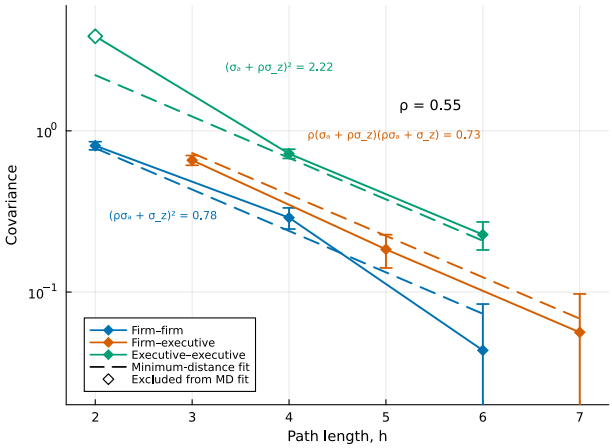
Azonos típusú végpontok, két további él: a kovariancia ρ^2-szeres.

$|\rho|$: a lecsengés üteméből, a skálaparaméterektől függetlenül.

Előjel: vegyes végpontú utak momentumaiból és az együttes likelihoodból.

Fán: a fenti képletek. Körök mellett: a tényleges hálózat kovarianciája.

A kovariancia lecsengése a magyar adatokban



A tartós különbségek elkülönítése az üzleti sokkoktól

Feltevés: a sokkok különböző vállalatok között függetlenek.

Vállalaton belüli korreláció:

Minimumtávolság: különböző vállalatok kovarianciái.

Vállalati átlagok: tetszőleges vállalaton belüli sokkkovariancia.

AR(1) likelihood: sokkperzisztencia becslése a vezetői időszakok között.

Ritka gráfokon is működő modell

A teljes hálózat modellje

A vállalati és vezetői látens típusok együttes eloszlása:

$$\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}^{-1}).$$

Ritka $\mathbf{Q}$: feltételes függés a szomszédok között; nulla a hiányzó éleknél.

Gauss-féle Markov-mező (GMRF) (Rue and Held 2005).

Az ismerős példa: AR(1) folyamat

Az $x_t = \rho x_{t-1} + u_t$ folyamat egy láncgráfon:

$$\mathbf{Q} \propto \begin{bmatrix} 1 & -\rho & & \\ -\rho & 1+\rho^2 & -\rho & \\ & -\rho & 1+\rho^2 & -\rho \\ & & -\rho & 1 \end{bmatrix}$$

Ritka precíziós mátrix, sűrű kovarianciamátrix

Az AR(1) folyamat mozgóátlag-reprezentációjához sűrű kovarianciamátrix tartozik:

$$\mathbf{\Sigma} = \mathbf{Q}^{-1} \propto \begin{bmatrix} 1 & \rho & \rho^2 & \rho^3 \\ \rho & 1 & \rho & \rho^2 \\ \rho^2 & \rho & 1 & \rho \\ \rho^3 & \rho^2 & \rho & 1 \end{bmatrix}$$

Parciális korreláció csak a szomszédok között van. A feltétel nélküli autokorreláció d késleltetésnél: ρ^d.

Erdőkön a paraméterek közvetlenül értelmezhetők

Erdőn:

$$\mathrm{Cov}(x_k, x_\ell) = \sigma_k \sigma_\ell \rho^{d(k,\ell)}.$$

Erdőn: $\mathrm{Var}(a) = \sigma_a^2$, $\mathrm{Var}(z) = \sigma_z^2$; szomszédok korrelációja ρ.

Körök mellett a momentumokat $\mathbf{Q}^{-1}$ adja.

Becslés az összes megtartott komponens felhasználásával

A típusok együttes eloszlását becsüljük: normális likelihood, ritka mátrixfaktorizáció.

Önálló pár: a teljesítmény teljes szóródása.

Hosszabb láncok: a kovariancia lecsengése.

A kovarianciamodell érvényességéhez kört záró éleket ritkítunk. Minden csúcs és komponens megmarad.

Hogyan szerepel a teljesítmény a becslésben?

Az i vállalat g időszakában az M_g vezetői csapat változatlan:

$$y_g = a_i + \frac{1}{|M_g|} \sum_{m \in M_g} z_m + \varepsilon_g.$$

Időszakonként egy teljesítményadat és hibatag, több vezető esetén is.

Négy szelekciós és skálaparaméter + vállalaton belüli perzisztencia (η).

Becslések és robusztusság

Erős a pozitív szelekció: $\rho \approx 0.52$–0.54

Log reálárbevétel, év–ágazat átlagoktól tisztítva. AR(1): a tanulmány fő becslése.

Paraméter	Naiv MLE	Min. távolság	Vállalati átlag	AR(1) MLE
ρ	0.379	0.542	0.536	**0.518**
Modell szerinti korr. (a, z)	0.381	0.549	0.543	0.525

Mit jelent a $\rho \approx 0.52$ érték?

Standardizált típusok korrelációja a ritkított, faszerű hálózaton:

$$\rho^d$$

ahol d a hálózati távolság.

Közvetlen szomszédok: 0.52. Két lépésre: 0.27. Négy lépésre: 0.07.

A kis komponensekkel több vállalatot érünk el

426,000 kisebb komponens: közel kétszer annyi csúcs, **59%-kal** több él.

Két módszer, többféle ritkítás: ρ változása legfeljebb **0.011**.

Mintabővítési összehasonlítás: év–ágazat átlagok és fokszámok kiszűrve; a fő AR(1)-becsléstől külön.

Az óriáskomponens vállalatai nagyobbak

	Óriáskomponens	Többi
Átlagos létszám	9.1	3.5
Átlagos logárbevétel	9.37	8.65
Feldolgozóipar	8.6%	9.5%
Alapító által vezetett	46.9%	72.2%

A teljesítmény parciális korrelációja a láncok mentén

432,114 izolált legrövidebb út; a közbülső teljesítmények kiszűrése után:

$$|\mathrm{PACF}| \leq 0.08 \qquad (h \geq 3).$$

A diagnosztikát a megfigyelt teljesítményekre számítjuk.

Különálló komponensek: kis negatív kovariancia

A GMRF szerint a különálló komponensek között pontosan nulla a kovariancia.

Mutató	Becslés
Külön komponensekből vett párok	58,785
Kovariancia (standard hiba)	$-0.0629\ (0.0208)$
Korreláció	≈ -0.013
Statisztikai próba	$\chi^2(10) = 21.38,\ p = 0.0186$

A nullát elutasítjuk; kicsi, negatív kovariancia. Közös tényező: pozitív korrelációt várnánk.

Gazdasági jelentőség

A szelekció érdemben hozzájárul az árbevétel szóródásához

AR(1)-becslés; a 2022-es aktív kapcsolatok feszítőerdője.

Összetevő	Részarány
Vállalati hatások	26.2%
Vezetői hatások	1.2%
Szelekciós kovariancia	**5.9%**
Párospecifikus zaj (vállalaton belül korrelált)	66.7%

Mennyit ér a szelekció?

Rögzítjük:

a vállalati adottságok és a vezetői képesség peremeloszlását;

a párospecifikus zaj szórását;

a párok számát.

A vállalatokat és vezetőket újrapárosítjuk.

Parciális egyensúly, AR(1)-becslés; a 2022-es kapcsolatok feszítőerdője.

Három alternatív párosítás

Alaphelyzet: $\ln E[R] = 1.799$.

Forgatókönyv	Várható árbevétel változása
Véletlen párosítás ($\rho = 0$)	-12.3%
Képességszórás megszüntetése, átlagmegőrzéssel ($\sigma_z \to 0$)	-12.3%
Tökéletes pozitív párosítás ($\rho = 1$)	$\approx +13.2\%$

A tökéletes pozitív párosítás elméleti felső korlát.

Hogyan értelmezzük a számítást?

Rögzített peremeloszlások és párospecifikus sokkok.

Lognormális modell: a vizsgált vállalatok várható árbevétele.

Új kérdés: közbeszerzések és vállalati hálózatok

Mennyibe kerül valójában egy autópálya vagy egy vasúti híd?

Az i ajánlatkérő a t tendert írja ki; a j cég ajánlatot tesz.

Lehetséges kiindulópont: tartós érték- és költségkülönbségek, tenderenkénti eltérésekkel.

$$v_{it} = v_i + \varepsilon^v_{it}, \qquad c_{jt} = c_j + \varepsilon^c_{jt}.$$

Az árat, p_{ijt}-t látjuk; az értéket és a költséget jellemzően nem. Kevés az összehasonlítható ügylet.

Milyen függetlenségi feltevések lennének hihetők az eltérésekre?

Az ár és a társadalmi többlet két külön kérdés

Egy egyszerű, önkéntes szerződésben: $c_{jt} \leq p_{ijt} \leq v_{it}$.

$$\begin{aligned} \text{Vevő nyeresége:} &\quad v_{it} - p_{ijt}, \\ \text{Eladó nyeresége:} &\quad p_{ijt} - c_{jt}, \\ \text{Együttes többlet:} &\quad v_{it} - c_{jt}. \end{aligned}$$

Az ár a többlet megosztásától is függ. A társadalmi kérdés: azok a párok szerződnek-e, amelyeknél nagy a többlet?

Magasabb költség vagy nagyobb árrés? Az árból önmagában nem válik szét.

Ki dönt arról, hogy létrejön-e a szerződés?

Átruházható hasznosság mellett az ár transzfer: az egyik fél kiadása a másik bevétele. Az együttes többletből kiesik. (Choo és Siow 2006)

Mi változik, ha a döntéshozó nem a közösség $v_{it} - p_{ijt}$ nyereségét követi, például magánelőnyhöz jut?

Lehetséges elméleti kiindulópont: párosítás tökéletlenül átruházható hasznossággal. (Galichon, Kominers és Weber 2019)

Ehhez még meg kellene fogalmazni az ajánlattétel és az elfogadás szabályát.

Mit tehetne hozzá a hálózat?

Ajánlatkérő–cég kapcsolatok; esetleg a cégek egymás közötti kapcsolatai.

Mutatnak-e ezek tartós együttmozgást a költségekben, az árrésekben vagy a szerződések létrejöttében?

Ha igen, segíthetne-e egy ritka hálózati modell elkülöníteni a tartós különbségeket a tenderenkénti eltérésektől?

Egyelőre modellötlet: a hálózat, az árképzés és az azonosítás még kidolgozandó.

Következtetések

A szelekció mérése ritka hálózatokon

Szelekció: a kovariancia lecsengése a mobilitási láncok mentén.

Ritka Gauss-modell: minden megtartott komponens felhasználása.

Magyarország: erős pozitív szelekció; véletlen párosítással **12.3%-kal** kisebb várható árbevétel.

Sűrű hálózatokon összevetés a leave-out módszerekkel.

További ritka hálózatok látens típusokkal

Példák: vevő–beszállító hálózatok és nemzetközi kereskedelem.

Páros és általános gráfokon is alkalmazható.

Függelék

A vezetők és a vállalatok párosításának egyszerű modellje

Az i vállalat az L munkát két rögzített tényezővel kombinálja: az A_i termelékenységgel és a vezető Z_m képességével (Lucas 1978). A w bér mellett a profitot maximalizáló létszámot választja:

$$\pi_{im} = \max_{L} \left\{ A_i Z_m^{\nu} L^{1-\nu} - wL \right\}.$$

Az optimális létszám mellett az árbevétel a *két rögzített tényező* Cobb–Douglas-függvénye:

$$Y_{im} = c(w) A_i^{1/\nu} Z_m.$$

A pozitív szelekció növeli a várható kibocsátást

Ha $a = \ln A/\nu + \ln c(w)$ és $z = \ln Z$ együttes eloszlása normális, a páronkénti várható árbevétel:

$$\mathbb{E}[Y_{im}] = \exp\left\{\mu_a + \mu_z + \tfrac{1}{2}(\sigma_a^2 + \sigma_z^2) + \mathrm{Cov}(a, z)\right\}.$$

Rögzített peremeloszlások mellett a várható összárbevétel nő a $\mathrm{Cov}(a, z)$ kovarianciával.

Hogyan mérhetjük a vezetői képességet?

Kérdőívek és naplók rögzítik, mivel foglalkoznak a vezetők (Bandiera et al 2020)

A végzettség, a tapasztalat és a vezetési stílus megfigyelhető közelítő mutatók.

A vállalatváltások segítenek elkülöníteni a vezetők tartós hozzájárulását (Bertrand and Schoar 2003, Abowd, Kramarz and Margolis 1999)

A vezetőváltások megmutatják a képességkülönbségeket

A vezetői képességet a vállalaton belüli vezetőváltásokból mérjük: $\Delta\widehat{z}_m \approx \Delta y_{im}$.

Az a_i és z_m hatásokat *paraméterként* kezeljük, és vállalati, illetve vezetői indikátorváltozókkal OLS-becslést végzünk.

Munkavállalók: (Abowd, Kramarz and Margolis 1999; Andrews et al 2008; Kline, Saggio and Sølvsten 2020). Vállalatvezetők: (Bertrand and Schoar 2003; Fenizia 2022; Metcalfe, Sollaci and Syverson 2023)

1. probléma: a fix hatásokhoz összefüggő komponens kell

A vállalati és vezetői hatásokat komponensenként külön normalizálással azonosítjuk.

A becsült hatások szintjét az adott komponens normalizálásához viszonyítjuk.

A szokásos becslési minta a legnagyobb komponens.

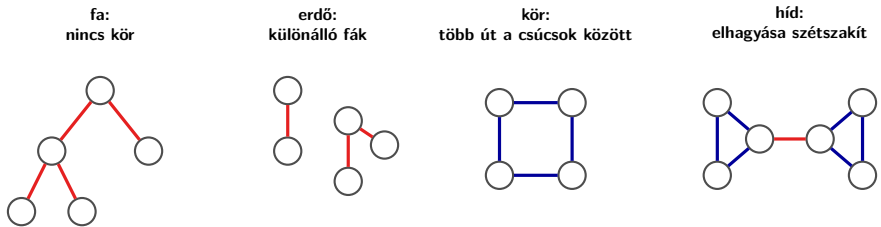
2. probléma: a zaj torzítja a második momentumokat

A ε hibatag zajossá teszi a becsült hatásokat.

A második momentumok becslése torzított: $\widehat{\mathrm{Var}}$ túl nagy, $\widehat{\mathrm{Cov}}$ túl kicsi (Andrews et al 2008; Kline, Saggio and Sølvsten 2020; Koren, Orbán and Telegdy 2025)

A kevés vállalatváltás mindkét problémát súlyosbítja.

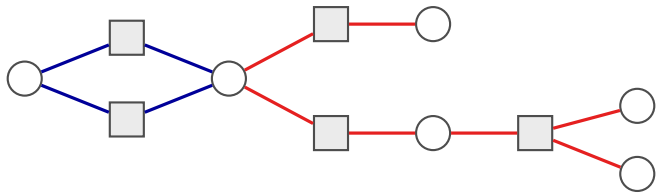
Fák, erdők, körök és hidak



A **híd** olyan él, amelynek elhagyása szétszakít egy összefüggő komponenst.

Egy fában *minden* él híd.

A leave-out korrekciókhoz körök kellenek



kék: körön van, leverage < 1 — használható

piros: híd, leverage $= 1$ — elhagyjuk

A négyzetek vállalatok, a körök vezetők, az élek vezetői megbízatások.

Szelekció egyetlen élen

Egy önálló élre, a fa építőelemére:

$$\begin{pmatrix} a_i \\ z_m \end{pmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} \sigma_a^2 & \rho\sigma_a\sigma_z \\ \rho\sigma_a\sigma_z & \sigma_z^2 \end{bmatrix}\right).$$

Itt ρ az él két végén álló típusok korrelációja.

Négy paraméter írja le a szelekciót

$$\boldsymbol{\theta} = (\sigma_a,\ \sigma_z,\ \rho,\ \sigma_\varepsilon)\,, \qquad \varepsilon_{im} \sim \mathcal{N}(0, \sigma_\varepsilon^2).$$

A szelekciót ρ méri. A három skálaparaméter a vállalatok, a vezetők és a párok közötti heterogenitást írja le.

A korreláció lecsengése a családfán

Clark a legtöbb rokoni kapcsolatra a következő összefüggést írja fel (Fisher 1918; Gimelfarb 1981; Clark 2023)

$$\rho_n = h^2 b^n, \qquad b = \frac{1+m}{2}.$$

Itt ρ_n az n rokonsági távolsághoz tartozó státuszkorreláció, h^2 az örökölhetőség, m pedig a házastársak genetikai értékei közötti korreláció.

Mi a helyzet a vállalaton belüli, időben korrelált sokkokkal?

Időben független, azonos eloszlású ε_{im} mellett:

$$\mathrm{Cov}(P - F - P) = (\sigma_a + \rho\sigma_z)^2$$

Autokorrelált sokkok mellett a mért kovariancia felfelé torzít.

A közös sokkok hatása **helyi**. A szelekciót a kovariancia **hosszú láncok menti lecsengésének üteme** azonosítja.

Párosítás előtt a típusok függetlenek

A kapcsolatok létrejötte előtt:

$$a_i \sim \mathcal{N}(0, \omega_a^2), \qquad z_m \sim \mathcal{N}(0, \omega_z^2).$$

A kapcsolódó vállalatok és vezetők közötti korreláció így a párok kiválasztódásából ered.

Létrejön-e a kapcsolat? Két kifizetés

$$\text{kapcsolat:} \quad \kappa + \frac{a_i z_m}{\tau},$$

$$\text{nincs kapcsolat:} \quad \frac{1}{\tau}\left(\alpha_1 a_i + \zeta_1 z_m + \frac{\alpha_2}{2} a_i^2 + \frac{\zeta_2}{2} z_m^2\right).$$

A $\tau > 0$ paraméter a párosítást nehezítő súrlódások mértékét adja meg. Az $a_i z_m$ tag komplementerré teszi a vállalati és vezetői típust. A lineáris és négyzetes tagok miatt a külső lehetőségek is típusfüggők.

A különbségük adja a logitindexet

Vezessük be a következő jelölést:

$$\eta(a_i, z_m) := \kappa + \frac{1}{\tau}\left[a_i z_m - \alpha_1 a_i - \zeta_1 z_m - \frac{\alpha_2}{2} a_i^2 - \frac{\zeta_2}{2} z_m^2\right].$$

A két állapot valószínűsége:

$$\Pr(L_{im} = 1 \mid a_i, z_m) = \frac{e^{\eta}}{1 + e^{\eta}}, \qquad \Pr(L_{im} = 0 \mid a_i, z_m) = \frac{1}{1 + e^{\eta}}.$$

A megfigyelt hálózat likelihoodja

A típusok és kapcsolatok együttes sűrűsége: a prior szorozva minden létrejött és elmaradt kapcsolat valószínűségével:

$$p(\mathbf{x}, E) \propto p_0(\mathbf{x}) \prod_{(i,m)\in E} \Pr(L_{im}{=}1 \mid \mathbf{x}) \prod_{(i,m)\notin E} \Pr(L_{im}{=}0 \mid \mathbf{x})$$

A kapcsolatok ritkák. Ha e^{η} kicsi:

$$\Pr(L_{im} = 1 \mid a_i, z_m) \simeq e^{\eta(a_i, z_m)} \qquad \text{az elmaradt kapcsolatok kiesnek.}$$

A **ritka kapcsolatok közelítésében** a létrejött kapcsolatok tényezőit használjuk.

Az így kapott eloszlás pontosan a GMRF-modellünk

Minden megfigyelt kapcsolat egy másodfokú tagot ad a kitevőhöz:

$$p_E^+(\mathbf{x}) \propto p_0(\mathbf{x}) \prod_{(i,m)\in E} e^{\eta(a_i,z_m)} \propto \exp\Big(-\frac{1}{2}\mathbf{x}^\top \mathbf{Q}\mathbf{x} + \mathbf{b}^\top \mathbf{x}\Big)$$

$$\mathbf{Q} = \underbrace{\mathbf{Q}_0}_{\text{független prior}} + \underbrace{\frac{1}{\tau}\mathbf{C}\mathbf{D}}_{\text{ismételt szelekció}} - \underbrace{\frac{1}{\tau}\mathbf{A}}_{\text{komplementaritás}} = \frac{1}{1-\rho^2}\mathbf{S}\left[(1-\rho^2)\mathbf{I} + \rho^2\mathbf{D} - \rho\mathbf{A}\right]\mathbf{S}$$

A $\tau = \sigma_a\sigma_z(1-\rho^2)/\rho$ választással a kapcsolatkeletkezési modell *pontosan előállítja* a varianciastabil precíziós mátrixot.

Mikor érvényes a közelítés?

A ritka kapcsolatok közelítése elhagyja a közös logitnevezőket.

A közelítés ritka, erdőszerű hálózaton érvényes; a sűrű, sok kört tartalmazó részeken sérül.

Ezért a sűrű magból **elhagyunk néhány kört záró élt**, és a közel erdőszerű hálózaton becslünk. Minden csúcsot és komponenst megtartunk.

A KSS a körökre épít, mi a fákra támaszkodunk. Így az adatok túlnyomó részét meg tudjuk tartani.

A likelihoodfüggvény

$$\ell(\boldsymbol{\theta}) = -\frac{K}{2}\ln(2\pi) - \frac{1}{2}\ln\det\boldsymbol{\Omega} - \frac{1}{2}\mathbf{y}^\top\boldsymbol{\Omega}^{-1}\mathbf{y}$$

$$\boldsymbol{\Omega} = \mathbf{V}\mathbf{Q}^{-1}\mathbf{V}^\top + \sigma_\varepsilon^2\mathbf{R} \qquad (\mathbf{V} \text{ az éleket a típusokhoz rendeli})$$

$$\mathbf{Q} = \frac{1}{1-\rho^2}\,\mathbf{S}\left[(1-\rho^2)\mathbf{I} + \rho^2\mathbf{D} - \rho\mathbf{A}\right]\mathbf{S}, \qquad \mathbf{S} = \operatorname{diag}(\sigma_a^{-1}\mathbf{I}_{N_f},\, \sigma_z^{-1}\mathbf{I}_{N_m})$$

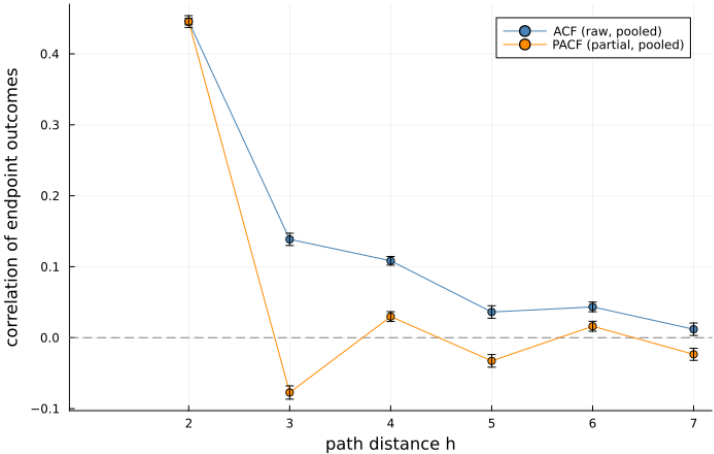
$\mathbf{A}$ a szomszédsági mátrix, $\mathbf{D}$ a fokszámok diagonális mátrixa. Az éleken ρ, a diagonálison skálaparaméterek szerepelnek.

Melyik becslést mikor használjuk?

Hálózat	Becslés
Sűrű (sok vállalatváltás)	leave-out (KSS), kis adatveszteség
Ritka, erdőszerű	GMRF
Köztes eset	mindkettő, majd összehasonlítás

A GMRF éppen a ritka hálózatoknál hasznos, ahol a leave-out korrekciók a legtöbb megfigyelést eldobják.

A nyers korreláció fennmarad, a parciális eltűnik



$h = 2$ mellett az ACF és a PACF megegyezik. $h \geq 3$ mellett a közbülső teljesítmények kiszűrése után a PACF közel nulla.

A leave-one-out korrekció és a leverage

Kline, Saggio és Sølvsten (2020) minden hatást az i megfigyelés *elhagyásával* becsülnek meg.

A fixhatás-becslések a teljesítményadatok lineáris függvényei. Az i megfigyelés a saját illesztett értékében h_i súllyal szerepel; ez a **leverage**. A torzításkorrekcióban az $1/(1-h_i)$ tényező szerepel.

Ha $h_i = 1$, a hatás *csak* az i megfigyelésből becsülhető. Ezeket a megfigyeléseket el kell hagyni.

$h_i = 1$ **pontosan akkor, ha az** i **él híd.**

Az előnyben részesített AR(1) modell paraméterei

$$\hat{\sigma}_a = 1.08, \qquad \hat{\sigma}_z = 0.24, \qquad \hat{\sigma}_\varepsilon = 1.72, \qquad \hat{\eta} = 0.51.$$

A korrelált párospecifikus sokk a tartós vállalaton belüli körülményeket ragadja meg.

A precíziós mátrix egyetlen élen

Vegyünk egy önálló vállalat–vezető párt; mindkét csúcs fokszáma 1:

$$\mathbf{Q}_{\{i,m\}} = \frac{1}{1-\rho^2}\begin{bmatrix} \sigma_a^{-2} & -\rho\,\sigma_a^{-1}\sigma_z^{-1} \\ -\rho\,\sigma_a^{-1}\sigma_z^{-1} & \sigma_z^{-2} \end{bmatrix} \iff \operatorname{Var}\begin{pmatrix} a_i \\ z_m \end{pmatrix} = \begin{bmatrix} \sigma_a^2 & \rho\,\sigma_a\sigma_z \\ \rho\,\sigma_a\sigma_z & \sigma_z^2 \end{bmatrix}$$

A $\mathbf{Q}$ főátlón kívüli elemei **csak a megfigyelt élek mentén** különböznek nullától.

Erdőn minden közvetlenül kapcsolódó pár korrelációja pontosan ρ.

Mi az a Gauss-féle Markov-mező?

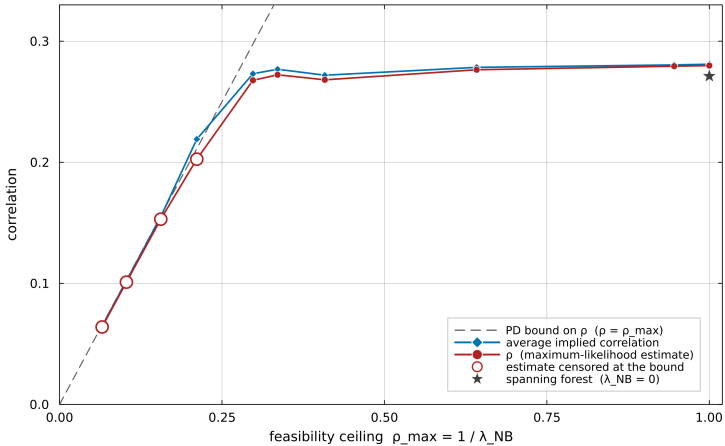
Együttesen normális eloszlású változók, **ritka precíziós mátrixszal**.

Nulla elem a $\mathbf{Q}$ mátrixban $\Leftrightarrow$ feltételes függetlenség az összes többi változó ismeretében.

A *feltételes* függés helyi: csak a közvetlen szomszédok között van.

A *feltétel nélküli* függés az utak mentén terjed.

A kört záró éleket elhagyjuk, a komponenseket megtartjuk



A kört záró élek ritkítása minden csúcsot és komponenst megtart.

Az alternatív párosítások számítási képlete

A páronkénti várható árbevétel a lognormális modellben:

$$\frac{Y}{n} = \exp\left\{\mu_a + \mu_z + \mu_\varepsilon + \tfrac{1}{2}\left(V_a + V_z + V_\varepsilon + 2\,\mathrm{Cov}(a, z)\right)\right\}$$

A peremeloszlásokat rögzítjük, megváltoztatjuk a párosítást, majd kiszámítjuk a várható kibocsátás változását.

Vezetői hatások a szakirodalomban

Fenizia (2022): olasz közintézmények vezetői; AKM-becslés Andrews és szerzőtársai (2008) korrekciójával. A vezetők csupán 24%-a vált munkahelyet. A torzításkorrigált felbontás a megfigyelések 21%-át tartja meg, a legnagyobb összefüggő halmazt.

Metcalfe, Sollaci és Syverson (2023): kiskereskedelmi vezetők, *negatív* becsült korreláció.

A zaj felfelé torzítja a becsült varianciákat, és negatív kovarianciát hoz létre a két becsült hatás között. Így a korreláció nullánál kisebb is lehet. A mechanizmust a függelék mutatja be.

Kapcsolódó tanulmányaink

Wohak és Koren (2025): leave-out becslés ritka gráfokon. A KSS és a GMRF a hálózat *más részeire* támaszkodik: a körökre, illetve a hidakra. A nagy leverage a hidakon kívül is zajossá teszi a második momentumok becslését. A zaj a nemnegativitási korlátokkal együtt torzítást okoz.

Koren, Orbán és Telegdy (2025): a vezetők értéke. Idősoros becslés, amely kiszűri a vállalaton belüli hibakorrelációból eredő látszólagos előtrendeket. A korrekció után a vezetőváltások nem mutatnak kapcsolatot a korábbi teljesítménnyel ugyanebben a magyar adatbázisban.

Köszönetnyilvánítás







A kutatást az Európai Kutatási Tanács (ERC Advanced Grant, 101097789. számú támogatási szerződés) és a Nemzeti Kutatási, Fejlesztési és Innovációs Hivatal (Élvonal Kutatási Kiválósági Program, 144193. számú szerződés) támogatta. Az előadásban kifejtett vélemények a szerzőké, és nem feltétlenül tükrözik az Európai Unió, az Európai Kutatási Tanács vagy az NKFI Hivatal hivatalos álláspontját.

Miért lehet negatív a fix hatások becsült korrelációja?

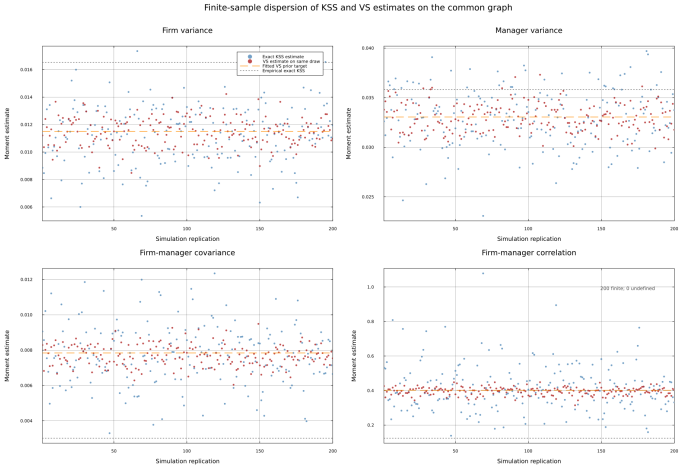
A fixhatás-becslések a teljesítményadatok lineáris kombinációi, így a zajt is tartalmazzák.

Ha egy zajtag *pozitív* súllyal kerül a vállalati hatás becslésébe, ugyanannál a párnál *negatív* súllyal kerül a vezetői hatásába: a két indikátorváltozó ugyanazt a változást osztja fel egymás között.

A túlbecsült varianciák nulla felé húzzák a korrelációt; a mechanikusan keletkező negatív kovariancia tovább csökkenti.

A szakirodalmi becslések alacsonyabbak, néha negatívak.

A leave-out becslés ott is zajos, ahol alkalmazható



Szimulációk azonos hálózaton: a KSS másodikmomentum-becslései (kék) sokkal jobban szóródnak, mint a GMRF-becslések (piros).

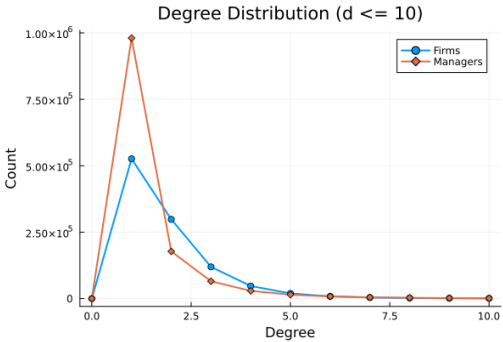
Modellilleszkedés: a logárbevétel varianciájának felbontása

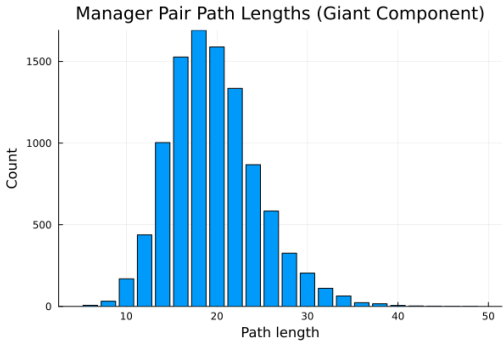
A tanulmány AR(1)-becslése alapján, a 2022-ben aktív kapcsolatok feszítőerdőjére számítva:

Összetevő	Részarány
Vállalati hatások	26.2%
Vezetői hatások	1.2%
Szelekciós kovariancia	5.9%
Párospecifikus zaj (vállalaton belül korrelált)	66.7%

A szelekciós kovarianciatag körülbelül ötszöröse a vezetői komponensnek.

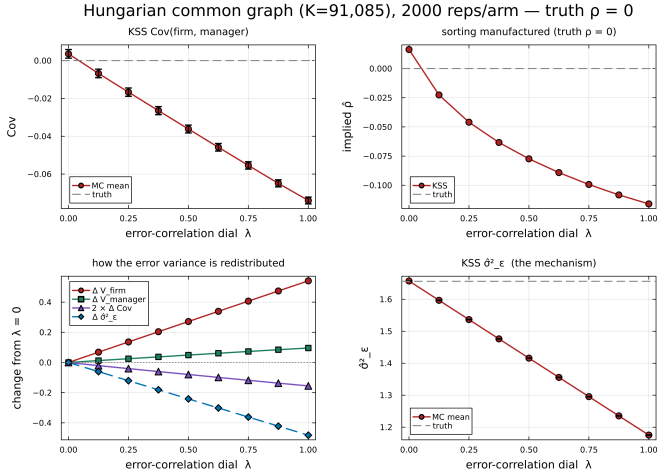
A páros mobilitási gráf





Az élek 42.8%-a az óriáskomponensben van; a többi jórészt önálló vállalat–vezető párokhoz tartozik.

Monte Carlo: korrelált hibák a magyar hálózaton



Hálózati olvasmányok

Sacerdote (2001), *Peer Effects with Random Assignment*

Jackson (2008), *Social and Economic Networks*

Bisztray, Koren and Szeidl (2018), *Learning to Import from Your Peers*

Erdős and Rényi (1959), *On Random Graphs I*

Barabási and Albert (1999), *Emergence of Scaling in Random Networks*

Barabási, *Network Science*; Hungarian edition

Olvasmányok a párosítási modellekhez

- Choo and Siow (2006), *Who Marries Whom and Why*
- Galichon, Kominers and Weber (2019), *Costly Concessions: An Empirical Framework for Matching with Imperfectly Transferable Utility*